

의료약물 정보 간의 연관성 분석



생명공학과 202002134 오재은
바이오메디컬공학부 202104415 윤수진

LIST

Chapter. 1

Data set

Chapter. 2

Hypothesis

Chapter. 3

Analysis

Chapter. 4

Conclusion

Chapter. 5

Expected Effect



Data Set

큰 데이터 # 문자열 변수

“250k Medicines Usage, Side Effects and Substitutes”

ID		Name	Substitute 0~4					Side Effect 0~41						Use0~4					Chemical class / Habit Forming /Therapeutic class /Action Class			
	id	name	substitute0	substitute1	substitute2	substitute3	substitute4	sideEffect0	sideEffect1	sideEffect2	...	sideEffect41		use0	use1	use2	use3	use4	Chemical Class	Habit Forming	Therapeutic Class	Action Class
0	1	augmentin 625 duo tablet	Penciclav 500 mg/125 mg Tablet	Moxikind-CV 625 Tablet	Moxiforce-CV 625 Tablet	Fightox 625 Tablet	Novamox CV 625mg Tablet	Vomiting	Nausea	Diarrhea	...	NaN	Treatment of Bacterial infections	NaN	NaN	NaN	NaN	NaN	NaN	No	ANTI INFECTIVES	NaN
1	2	azithral 500 tablet	Zithrocare 500mg Tablet	Azax 500 Tablet	Zady 500 Tablet	Cazithro 500mg Tablet	Trulimax 500mg Tablet	Vomiting	Nausea	Abdominal pain	...	NaN	Treatment of Bacterial infections	NaN	NaN	NaN	NaN	NaN	Macrolides	No	ANTI INFECTIVES	Macrolides
2	3	ascoril ls syrup	Solvin LS Syrup	Ambrodil-LX Syrup	Zerotuss XP Syrup	Capex LS Syrup	Broxum LS Syrup	Nausea	Vomiting	Diarrhea	...	NaN	Treatment of Cough with mucus	NaN	NaN	NaN	NaN	NaN	NaN	No	RESPIRATORY	NaN
3	4	allegra 120mg tablet	Lcfex Tablet	Etofex 120mg Tablet	Nexofex 120mg Tablet	Fexise 120mg Tablet	Histafree 120 Tablet	Headache	Drowsiness	Dizziness	...	NaN	Treatment of Sneezing and runny nose due to al...	Treatment of Allergic conditions	NaN	NaN	NaN	NaN	Diphenylmethane Derivative	No	RESPIRATORY	Antihistaminics (second Generation)
248217	248218	zyvocol 1% dusting powder	Canazole Dusting Powder	Clotrex Dusting Powder	AF -C Dusting Powder	Klo-Aid Dusting Powder	Nuforce Dusting Powder	Blisters	Skin peeling	Swelling	...	NaN	Treatment of Fungal skin infections	NaN	NaN	NaN	NaN	NaN	Azole derivatives {Imidazoles}	No	DERMA	Fungal ergosterol synthesis inhibitor

248218 rows × 58 columns

248,218 rows × 58 columns

Dataset link: <https://www.kaggle.com/datasets/shudhanshusingh/250k-medicines-usage-side-effects-and-substitutes>

Motivation

“250k Medicines Usage, Side Effects and Substitutes”

의약품의 부작용에 밀접하게
영향을 미치는 Attribute는
무엇일까 ??

Substitute

Use

Side Effect

Chemical
Class

Therapeutic
Class

Hypothesis



Side Effect \leftrightarrow The Other Attribute


Side Effect를 중심으로 side effect와

특정 Attribute 사이에 연관성이 있다고 가정

=> Regression



기법선택이유



전체 데이터에서 side effect에 영향을 주는 요인들을
분석하기 위해 regression model을 생성하여
side effect에 영향을 미치는 요인들에 대한
importance를 확인하고자 함

=> **Regression**

[illegible]

Data Preprocessing

1. 각 attribute 마다 missing value의 비율이 45% 이상이면 attribute 제거
→ **dimension 축소**

```
[ ] df1.isnull().sum()

↔ id          0
   name       0
   substitute0 9597
   substitute1 14351
   substitute2 17985
   substitute3 21362
   substitute4 24256
   sideEffect0 0
   sideEffect1 9802
   sideEffect2 18718
   sideEffect3 40580
   sideEffect4 84658
   use0        0
   Chemical Class 110427
   Habit Forming 0
   Therapeutic Class 69
   Action Class 110182
   dtype: int64
```

2. Use0(약물 사용 목적) 에서 빈도가 높은 상위 15개의 사용 목적만 남기고 나머지 값은 제거

```
[ ] df2.isnull().sum()

↔ id          0
   name       0
   substitute0 2545
   substitute1 3878
   substitute2 4908
   substitute3 5916
   substitute4 6772
   sideEffect0 0
   sideEffect1 1845
   sideEffect2 5704
   sideEffect3 21166
   sideEffect4 47840
   use0        0
   Chemical Class 66427
   Habit Forming 0
   Therapeutic Class 9
   Action Class 66286
   dtype: int64
```

3. 나머지 null 값 확인 후 전부 제거

```
df3.isnull().sum()


id          0
name        0
substitute0 0
substitute1 0
substitute2 0
substitute3 0
substitute4 0
sideEffect0 0
sideEffect1 0
sideEffect2 0
sideEffect3 0
sideEffect4 0
use0        0
Chemical Class 0
Habit Forming 0
Therapeutic Class 0
Action Class 0
dtype: int64
```

4. Label encoding

- 모든 **문자열** → **숫자**로 변환

5. 전처리 후 Data Shape : (34859,16)

Linear Regression



Mean Squared Error: 128.46215053720954

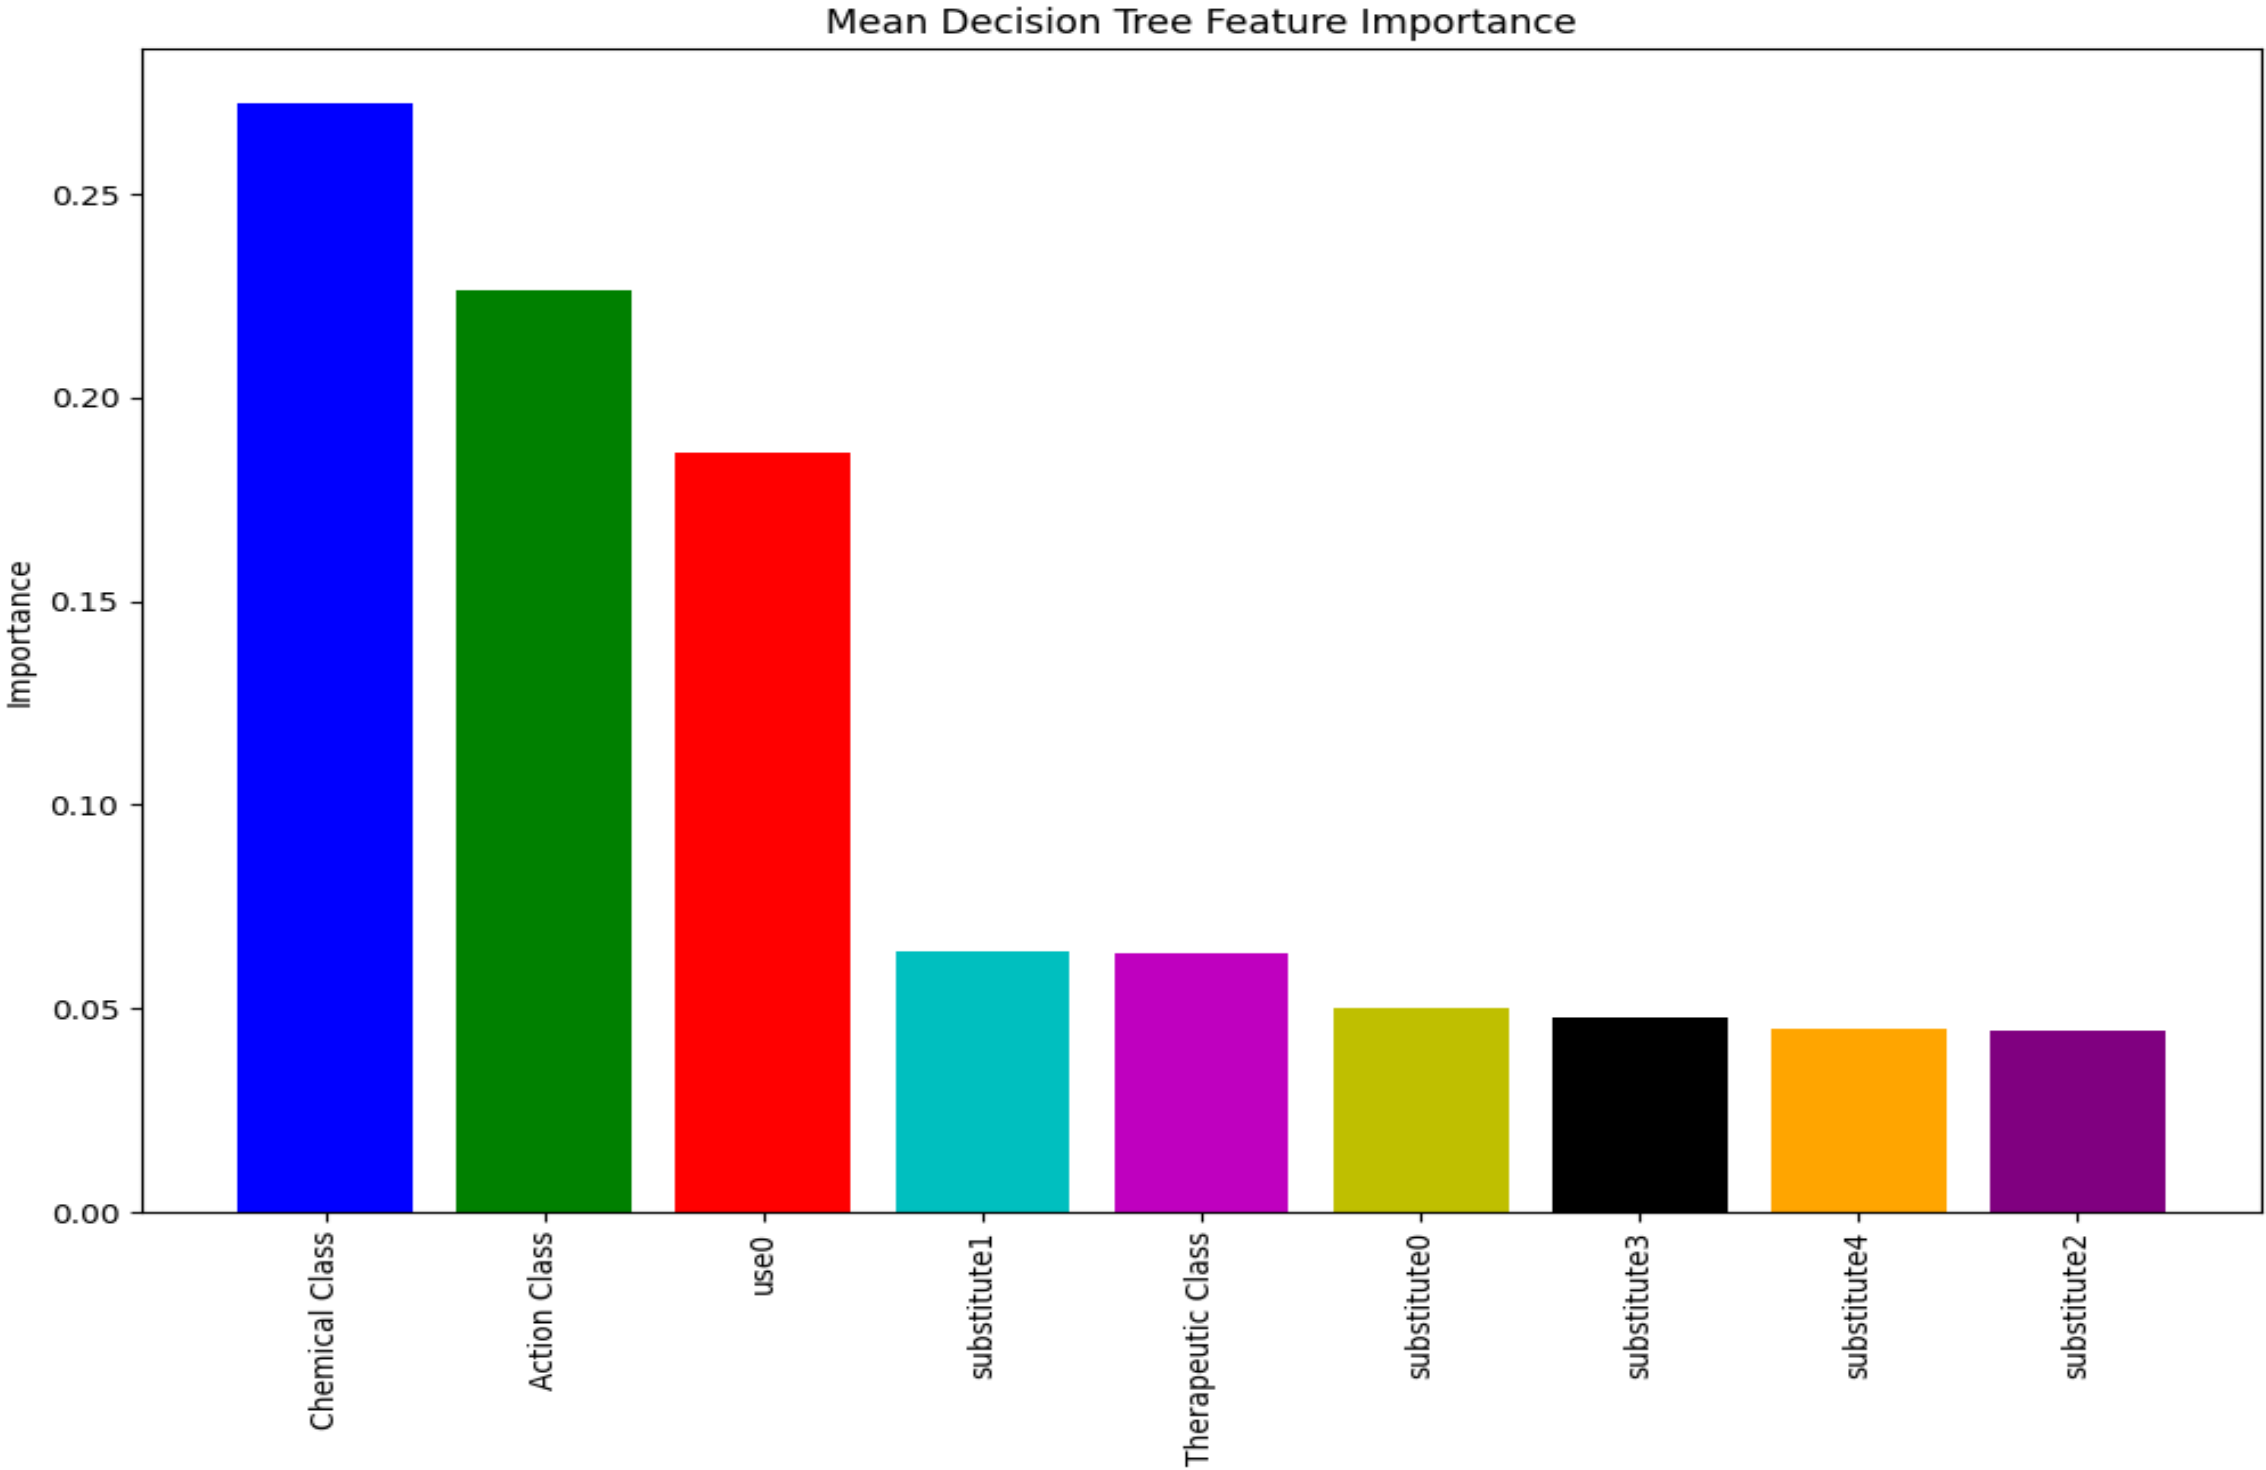
R² Score: 0.20824906022893785

	Coefficient
substitute0	-0.002113
substitute1	-0.001490
substitute2	0.001770
substitute3	0.000999
substitute4	-0.000981
use0	1.515184
Chemical Class	0.016376
Therapeutic Class	0.454804
Action Class	-0.074955

한계: R² Score 값이 0.2로 낮음

Decision Tree

Side effect 0~4까지 총 5개의 모델을 생성 → 수치의 평균을 내어 **Importance** 시각화



Decision Tree Feature **Importance**:


	Importance
Chemical Class	0.272018
Action Class	0.226378
use0	0.186317
substitute1	0.064070
Therapeutic Class	0.063603
substitute0	0.049972
substitute3	0.047883
substitute4	0.045149
substitute2	0.044610

두 경우 모두 **Chemical Class, Action Class** 가 높은 **Importance**로 나타남

Random Forest

Side effect 0~4까지 총 5개의 모델을 생성 → 수치의 평균을 내어 **Importance** 시각화

Mean Random Forest Feature Importance



Random Forest Feature **Importance**:

	Importance
Chemical Class	0.276567
Action Class	0.216396
use0	0.181050
Therapeutic Class	0.069960
substitute1	0.059942
substitute2	0.054579
substitute0	0.054125
substitute4	0.045281
substitute3	0.042101

두 경우 모두 **Chemical Class, Action Class** 가 높은 **Importance**로 나타남

Decision Tree & Random Forest


	Model	Side Effect	MSE	R2 Score
1	Decision Tree Regression	sideEffect0	1.481476779796572	0.9923191872200287
2	Random Forest Regression	sideEffect0	0.5957805026601601	0.9969111372103191
3	Decision Tree Regression	sideEffect1	1.0390769233893924	0.994254168520173
4	Random Forest Regression	sideEffect1	0.7508517318008353	0.9958479806257355
5	Decision Tree Regression	sideEffect2	1.4662937464142283	0.9918930692134506
6	Random Forest Regression	sideEffect2	0.6684613310384394	0.9963041718226885
7	Decision Tree Regression	sideEffect3	2.897989661564318	0.9850880131447765
8	Random Forest Regression	sideEffect3	1.7007206069806233	0.9912487184919725
9	Decision Tree Regression	sideEffect4	2.425487247278833	0.980787904032907
10	Random Forest Regression	sideEffect4	1.4696852792696595	0.988358737132743

Side effect 0,1,2,3,4의 R^2 score 값이 모두 높음

* R square : 독립변수가 종속변수를 얼마나 잘 설명하는지를 나타냄 (0에서 1사이의 값)

Chemical Class & Side effect

Top 10 Chemical Classes by Frequency



1. Chemical Class 내에서 빈도 수 체크

→ 27, 71, 33이라는 chemical class순으로
가장 많이 존재

2. 특정 chemical class 내에서 side effect
빈도 수 체크

→ Chemical Class 27에서 가장 빈도가 높은
SideEffect 값: 16

Chemical Class 71에서 가장 빈도가 높은
SideEffect 값: 6

Chemical Class 33에서 가장 빈도가 높은
SideEffect 값: 35

Label encoding 값을 다시 decoding하면 어떤 chemical class가
어떤 side effect 발생에 영향을 미치는지에 대한 이해를 도울 수 있음

Data Decoding

Chemical Class 27에서 가장 빈도가 높은 SideEffect0 값: 16
Chemical Class 71에서 가장 빈도가 높은 SideEffect0 값: 6
Chemical Class 33에서 가장 빈도가 높은 SideEffect0 값: 35

Chemical Class 27에서 가장 빈도가 높은 SideEffect1 값: 7
Chemical Class 71에서 가장 빈도가 높은 SideEffect1 값: 15
Chemical Class 33에서 가장 빈도가 높은 SideEffect1 값: 36



Chemical Class 27에서 가장 빈도가 높은 SideEffect0 값: 16 [Akathisia (inability to stay still)]
Chemical Class 71에서 가장 빈도가 높은 SideEffect0 값: 6 [Abnormal liver function tests]
Chemical Class 33에서 가장 빈도가 높은 SideEffect0 값: 35 [Argyria (skin turns blue or bluish-grey)]


Chemical Class 27에서 가장 빈도가 높은 SideEffect1 값: 7 [Accommodation disorder]
Chemical Class 71에서 가장 빈도가 높은 SideEffect1 값: 15 [Allergic skin rash]
Chemical Class 33에서 가장 빈도가 높은 SideEffect1 값: 36 [Blisters on skin]

Chemical Class 27: [Acetic acid Derivatives]
Chemical Class 71: [Amino Acids, Peptides, and Analogues]
Chemical Class 33: [Acylsalicylamides (Benzoic acids and derivatives)]

Chemical<->Action<->Side Effect

Correlation matrix Heat Map

- Action class와 Chemical class 사이의 상관관계가 높은 것으로 보아 서로 종속적인 관계가 있는 것으로 추측
- 다른 독립 변수들도 연관성의 요인으로 고려해보는 것이 필요



Conclusion & 한계점

결론

- 'Chemical class' 와 'Action class'가 약물의 부작용에 높은 중요도를 가진다.

한계점

- 문자열 데이터 & 많은 N-1 값으로 전처리 과정에 어려움,
다양한 기법을 사용해도 유의미한 결과를 찾는 데에 많은 시간 소요 발생
- Label encoding한 수치들을 다시 Decoding 하는 과정이 필요

Expected Effect



기대효과 1

* 부작용이 약물의 어떤 특성과 연관이 있는지 확인
=> 의약품 연구에 활용 가능.



기대효과 2

* 연관성 있는 attribute의 종류에 따라 어떤 부작용이 발생할 수 있는지 예측
=> 대체 의약품 개발에 도움.





THANK YOU

